

# **PART 1**

## **DATA INGESTION**

## TASK

1. We have already learned how to create DataFrame from files [here](#). Now, we are going to create a DataFrame from a larger [csv file](#) on our [datasets](#).
2. Rename all the columns with snake\_case format.
3. Select only 10 top of highest number of `passenger_count`, show only columns `vendor_id`, `passenger_count`, `trip_distance`, `payment_type`, `fare_amount`, `extra`, `mta_tax`, `tip_amount`, `tolls_amount`, `improvement_surcharge`, `total_amount`, `congestion_surcharge` from the DataFrame.
4. [Extra] Cast the data type to the appropriate value.

# Setup Environment & Install Requirements.txt



Hal yang pertama dilakukan untuk mengerjakan tugas adalah clone repository yang sudah disediakan

**git clone** <https://github.com/Immersive-DataEngineer-Resource/ingestion-data.git>

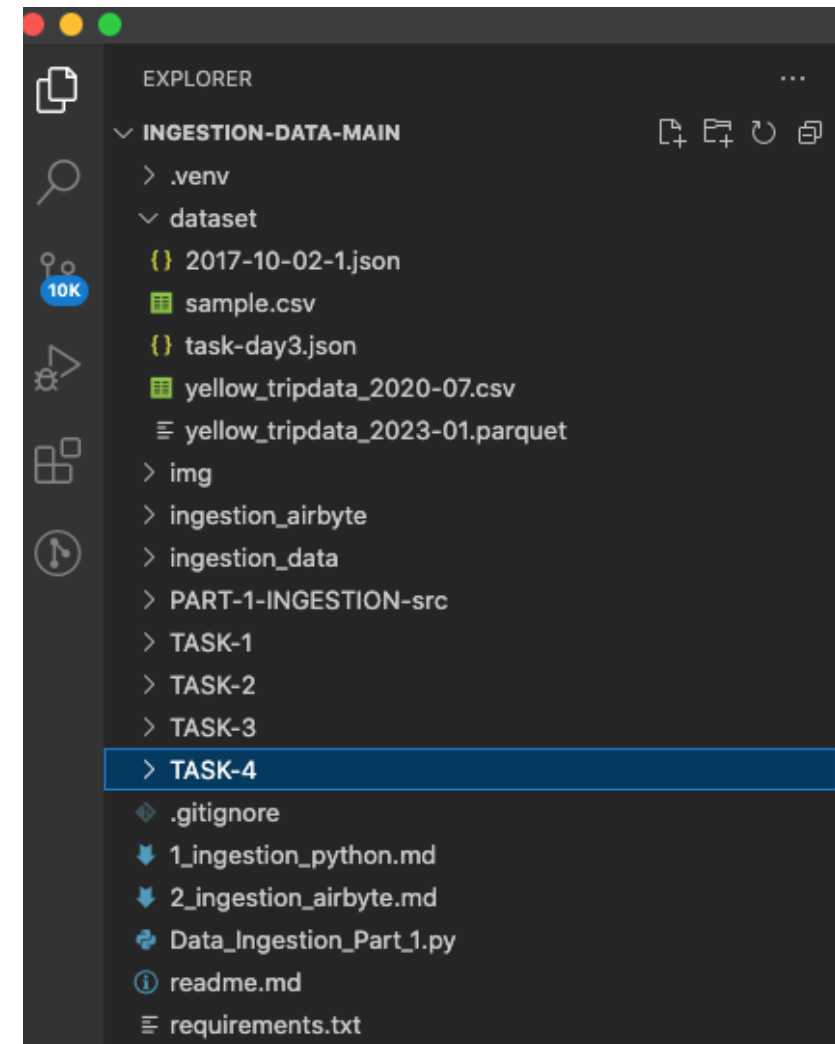
Bisa dilihat pada gambar disamping jika virtual environment sudah terinstall maka setelah itu bisa menggunakan perintah

**source .venv/bin/activate**

```
(.venv) wartadi@Wartadis-MacBook-Pro ingestion-data-main %
```

**pip install -r requirements.**

Daftar requirements.txt mencakup paket-paket yang diperlukan untuk



# TASK 1

## Input Program

```
def main():  
    # 1. Memuat dataset dengan low_memory=False untuk menangani peringatan tipe campuran  
    df = pd.read_csv(os.path.join(os.path.dirname(__file__), "../dataset/yellow_tripdata_2020-07.csv"), low_memory=False)
```

Dataset dimuat dari file yellow\_tripdata\_2020-07.csv. Parameter low\_memory=False digunakan untuk menangani peringatan tipe data campuran yang mungkin muncul saat membaca file besar.

## Output

```
(.venv) wartadi@Wartadis-MacBook-Pro PART-1-INGESTION-src % python tugas_part1_ingestion.py  
1. DataFrame setelah memuat dataset:
```

Index	VendorID	tpep_pickup_datetime	tpep_dropoff_datetime	passenger_count	trip_distance	RatecodeID	store_and_fwd_flag	Other columns
0	1.0	2020-07-01 00:25:32	2020-07-01 00:33:39	1.0	1.5	1.0	N	Other columns (11 more)
1	1.0	2020-07-01 00:03:19	2020-07-01 00:25:43	1.0	9.5	1.0	N	Other columns (11 more)
2	2.0	2020-07-01 00:15:11	2020-07-01 00:29:24	1.0	5.85	1.0	N	Other columns (11 more)
3	2.0	2020-07-01 00:30:49	2020-07-01 00:38:26	1.0	1.9	1.0	N	Other columns (11 more)
4	2.0	2020-07-01 00:31:26	2020-07-01 00:38:02	1.0	1.25	1.0	N	Other columns (11 more)

```
Showing 7 columns out of 18 total columns.  
Hidden columns (11): PULocationID, DOLocationID, payment_type, fare_amount, extra, mta_tax, tip_amount, tolls_amount, improvement_surcharge, total_amount, congestion_surcharge
```

# TASK 2

## Input Program

```
# 2. Mengganti nama kolom menjadi snake_case
df.columns = df.columns.str.lower().str.replace(' ', '_')

# Menampilkan nama-nama kolom setelah diganti menjadi snake_case
print("2. Nama kolom setelah diganti menjadi snake_case:")
print(df.columns.tolist())
print("\n")
```

Nama kolom diubah menjadi huruf kecil dan format snake\_case (mengganti spasi dengan underscore \_).

## Output Program

```
2. Nama kolom setelah diganti menjadi snake_case:
['vendorid', 'tpep_pickup_datetime', 'tpep_dropoff_datetime', 'passenger_count', 'trip_distance', 'ratecodeid', 'store_and_fwd_flag', 'pulocationid', 'dolocationid', 'payment_type', 'fare_amount', 'extra', 'mta_tax', 'tip_amount', 'tolls_amount', 'improvement_surcharge', 'total_amount', 'congestion_surcharge']
```

# TASK 3

## Input Program

```
# 3. Memilih kolom-kolom yang relevan dan 10 baris teratas dengan jumlah penumpang tertinggi
selected_columns = [
    'vendorid', 'passenger_count', 'trip_distance', 'payment_type',
    'fare_amount', 'extra', 'mta_tax', 'tip_amount', 'tolls_amount',
    'improvement_surcharge', 'total_amount', 'congestion_surcharge'
]
df_selected = df[selected_columns]

# Memilih 10 baris teratas dengan jumlah penumpang tertinggi
top_10_passenger_count = df_selected.nlargest(10, 'passenger_count')

print("3. 10 baris teratas dengan jumlah penumpang tertinggi:")
print_table_with_summary(top_10_passenger_count)
print("\n")
```

- Beberapa kolom yang relevan dipilih dari DataFrame asli.
- 10 baris dengan jumlah penumpang tertinggi dipilih menggunakan nlargest.

## Output Program

3. 10 baris teratas dengan jumlah penumpang tertinggi:

Index	vendorid	passenger_count	trip_distance	payment_type	fare_amount	extra	mta_tax	tip_amount	tolls_amount	Other columns
214141	2.0	9.0	0.0	1.0	9.8	0.0	0.0	1.96	0.0	Other columns (3 more)
79823	2.0	8.0	0.0	1.0	8.5	0.0	0.0	1.0	0.0	Other columns (3 more)
737023	2.0	8.0	0.0	1.0	8.0	0.0	0.0	0.0	0.0	Other columns (3 more)
164792	2.0	7.0	0.0	1.0	7.0	0.0	0.5	1.0	0.0	Other columns (3 more)
385688	2.0	7.0	0.0	2.0	7.3	0.0	0.5	0.0	0.0	Other columns (3 more)
385689	2.0	7.0	0.0	1.0	7.3	0.0	0.5	3.18	0.0	Other columns (3 more)
690829	2.0	7.0	0.0	1.0	7.0	0.0	0.5	1.0	0.0	Other columns (3 more)
732901	2.0	7.0	10.84	1.0	70.0	0.0	0.0	0.0	0.0	Other columns (3 more)
65	2.0	6.0	0.73	2.0	4.0	0.5	0.5	0.0	0.0	Other columns (3 more)
144	2.0	6.0	1.09	1.0	5.0	0.5	0.5	2.64	0.0	Other columns (3 more)

Showing 9 columns out of 12 total columns.  
Hidden columns (3): improvement\_surcharge, total\_amount, congestion\_surcharge

# Task 4

## Input Program

```
# 4. Mengubah tipe data dan menampilkan DataFrame setelah casting
print("4. Nilai NaN sebelum mengubah tipe data:")
print(df_selected.isna().sum())
print("\n")

# Menggunakan .loc untuk mengisi nilai NaN dan mengubah tipe
df_selected.loc[:, 'vendorid'] = df_selected['vendorid'].fillna(0).astype(int)
df_selected.loc[:, 'passenger_count'] = df_selected['passenger_count'].fillna(0).astype(int)

float_columns = [
    'trip_distance', 'fare_amount', 'extra', 'mta_tax', 'tip_amount',
    'tolls_amount', 'improvement_surcharge', 'total_amount', 'congestion_surcharge'
]
for col in float_columns:
    df_selected.loc[:, col] = df_selected[col].fillna(0.0).astype(float)

# Menampilkan DataFrame setelah mengubah tipe data
print("4. DataFrame setelah mengubah tipe data:")
print_table_with_summary(df_selected.head())
print("\n")
```

Nilai NaN di kolom vendorid dan passenger\_count diisi dengan 0 dan diubah menjadi tipe data int. Kolom-kolom yang seharusnya bertipe float juga diisi dengan 0.0 dan diubah menjadi tipe float.



# Task 4

## Output Program

4. Nilai NaN sebelum mengubah tipe data:

```
vendorid      62847
passenger_count 62847
trip_distance  0
payment_type   62847
fare_amount    0
extra          0
mta_tax        0
tip_amount     0
tolls_amount   0
improvement_surcharge 0
total_amount   0
congestion_surcharge 0
dtype: int64
```

4. DataFrame setelah mengubah tipe data:

Index	vendorid	passenger_count	trip_distance	payment_type	fare_amount	extra	mta_tax	tip_amount	tolls_amount	Other columns
0	1.0	1.0	1.5	2.0	8.0	0.5	0.5	0.0	0.0	Other columns (3 more)
1	1.0	1.0	9.5	1.0	26.5	0.5	0.5	0.0	0.0	Other columns (3 more)
2	2.0	1.0	5.85	2.0	18.5	0.5	0.5	0.0	0.0	Other columns (3 more)
3	2.0	1.0	1.9	1.0	8.0	0.5	0.5	2.36	0.0	Other columns (3 more)
4	2.0	1.0	1.25	2.0	6.5	0.5	0.5	0.0	0.0	Other columns (3 more)

Showing 9 columns out of 12 total columns.

Hidden columns (3): improvement\_surcharge, total\_amount, congestion\_surcharge



THANK YOU 😊

